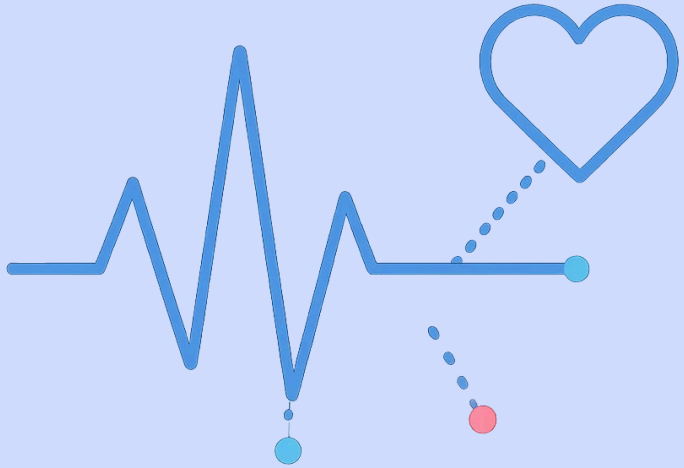

Heart Disease Prediction

Projet Machine Learning

Réalisé par : Aya LOGHMARI

Made with GAMMA

Problématique

Problématique

Les maladies cardiovasculaires sont une cause majeure de mortalité dans le monde.

Objectif

Prédire la présence d'une maladie cardiaque à partir de données médicales des patients.

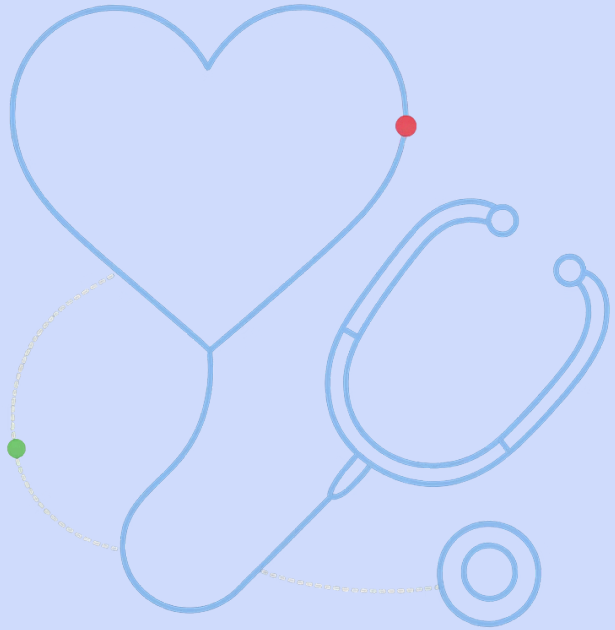

Made with GAMMA

Dataset

Source

Kaggle – Heart Disease Dataset

Caractéristiques

- Environ 1000 lignes
- 13+ variables

Exemples de variables

- Age
- Cholestérol
- Pression artérielle
- Type de douleur thoracique

Made with GAMMA

Analyse Exploratoire (EDA)

L'EDA est une étape qui consiste à explorer et comprendre les données avant de construire un modèle de Machine Learning.

- Analyse des distributions des variables
- Étude des corrélations entre les features
- Détection des valeurs manquantes

Conclusion : Certaines variables influencent fortement la présence de la maladie cardiaque.

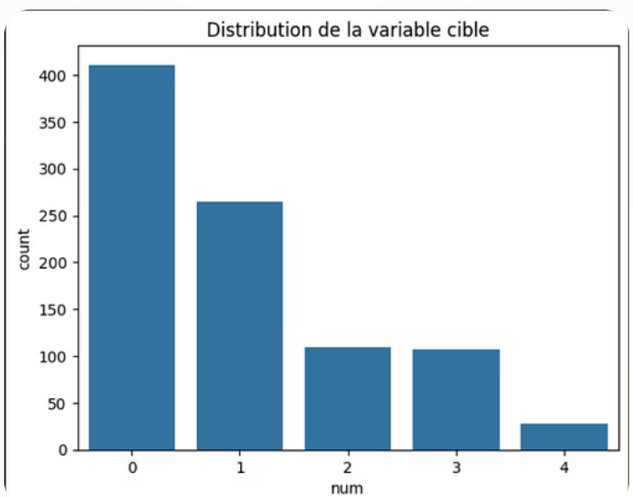

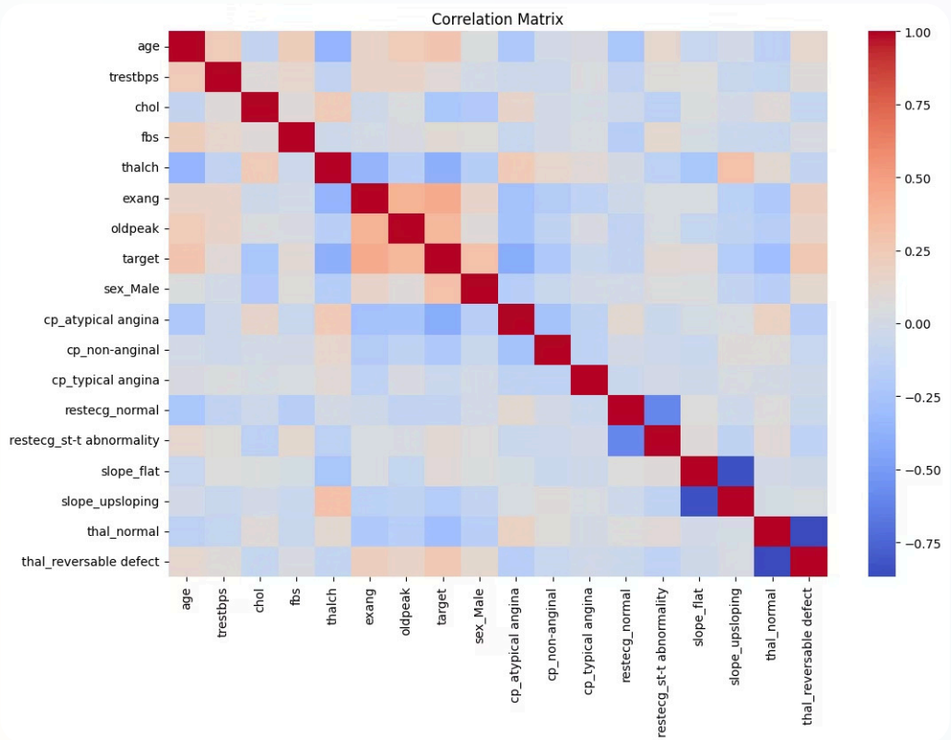

Made with GAMMA

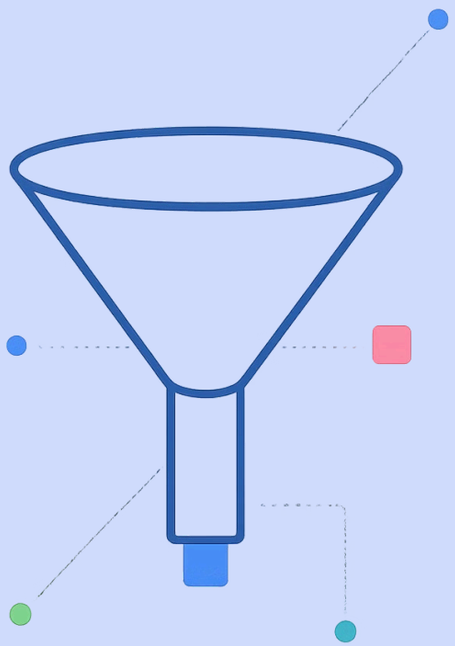

Prétraitement des données

Nettoyage des données

NaN, doublons

Encodage des variables catégorielles

One-Hot Encoding pour transformer les variables catégorielles en variables numériques.

Normalisation des données

permet de mettre tous les variables à la meme échelle.

Transformation de la variable cible

En binaire (0/1)

Équilibrage

vérification de déséquilibrage.

Made with GAMMA

Modélisation

Type de problème

Classification supervisée.

- Classification : car la sortie est binaire donc on prédit un classe et non une valeur continue.
- supervisée : car nous avons une variable cible déjà connue dans les données.

Méthode

Séparation des données en Train / Test

- Train set : partie des données utilisée pour apprendre le modèle.
- Test set : partie séparée des données, utilisée uniquement pour évaluer le modèle après l'apprentissage.

Modèles utilisés

1

Logistic Regression

est un modèle simple qui calcule la probabilité qu'un patient ait une maladie.

2

K-Nearest Neighbors (KNN)

prédit la classe d'un patient en regardant les patients les plus proches dans les données.

3

Random Forest

un ensemble de plusieurs arbres de décision. chaque arbre fait une prédiction puis le modèle prend la majorité.

Made with GAMMA

Résultats

Métriques utilisées

Accuracy : mesure la pourcentage de bonnes prédiction.

Precision : mesure parmi les prédiction positives combient sont correcte

Recall : mesure parmi les vraies valeur positif combien ont été correctement détectée.

F1-score : une moyenne hérmonique entre la précision et le rappel utile quand les classes sont déséquilibrées.

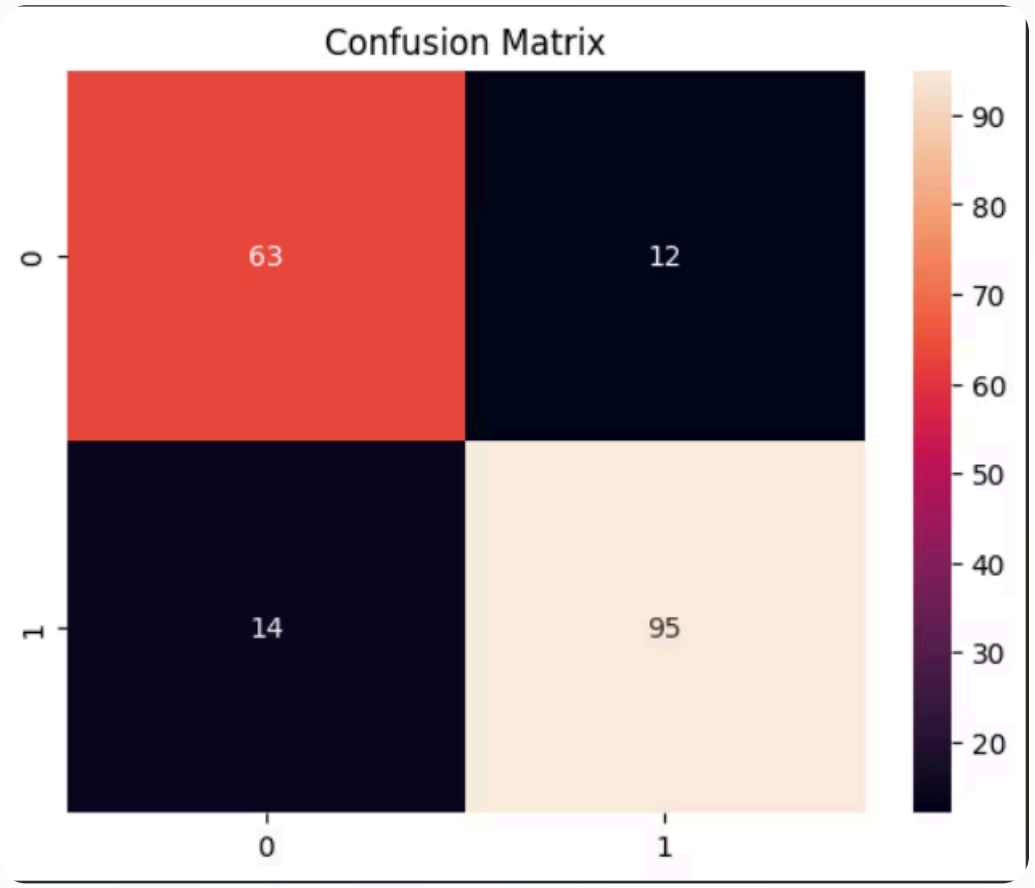

Comparaison des modèles

Random Forest

→ meilleur score

KNN

→ performance moyenne

Logistic Regression

→ correcte

Made with GAMMA

Conclusion

Résumé

- Problème de classification supervisée
- Random Forest offre les meilleures performances

Limites

- Résultats dépendants des données
- Ne remplace pas un diagnostic médical

Bonus

Application Streamlit permettant de tester le modèle en temps réel

Made with GAMMA

Application

Interface simple avec Streamlit

L'utilisateur entre les données

Le modèle prédit la présence de maladie

→ **Démonstration en temps réel**

Made with GAMMA